

PARTIE X Programmation parallèle

Bruno Bachelet Loïc Yon

Applications parallèles (1/2)

- Développement des processeurs multicoeurs
 - Limitation technique à l'augmentation des fréquences d'horloge
 - Nouvelle voie d'amélioration des performances d'une application
- Applications avec interface graphique nécessairement parallèles
 - □ 1 thread → interface graphique (gestion des événements)
 - □ 1 ou plusieurs threads → application métier
 - Evite le gel de l'interface graphique
- Beaucoup d'applications peuvent bénéficier du parallélisme
 - Possibilité d'exécution de tâches en parallèle
 - Réduction des temps de latence d'un programme
 - Accès à une ressource système (mémoire, fichier...) ⇒ latence
 - Mécanisme de mise en attente d'un thread ⇒ gain même sur un seul coeur
 - Règle empirique: souvent «optimal» pour nombre de threads = 2 x nombre de coeurs

Applications parallèles (2/2)

- La conception d'une application parallèle est difficile
 - Choisir la granularité des tâches à paralléliser
 - Synchroniser les tâches
 - Contrôler l'accès aux ressources partagées
- Avant C++11: bibliothèques/extensions non standards
 - POSIX Threads, OpenMP...
- Depuis C++11: API objet standard
 - Couche bas niveau (équivalent POSIX): thread, mutex...
 - Couche intermédiaire (abstraction): async, future...
- Avec C++17
 - Couche haut niveau (algorithmes parallèles): for_each, reduce...

Principe du thread

- Représente un nouveau fil d'exécution dans le programme
- Nouveau contexte d'exécution
 - Possède sa propre pile
- Mais partage des données
 - Accès (lecture/écriture) au tas du programme
 - Attention aux accès concurrents
- A ne pas confondre avec un processus
 - Granularité plus fine
 - Intra-programme vs. inter-programme
 - Plus léger
 - Moins de consommation de ressources
 - Processeurs adaptés aux threads

Classe *«thread»* (1/2)

- Entête: #include <thread>
- Threads représentés par la classe «thread»
 - Deux états sont possibles
 - Actif: représente une exécution parallèle effectivement en cours
 - Inactif: symbolise un thread, mais aucune exécution parallèle effective
 - Pour savoir si le thread est actif: méthode «joinable»
 - Possède un identifiant unique: méthode «get_id»
 - Peut être utilisé comme clé dans un conteneur associatif
- Un thread démarre lors de sa construction
 - Si on lui fournit un «callable» (i.e. fonction, foncteur ou lambda)
 - Ce callable est automatiquement exécuté au lancement du thread
 - Des arguments peuvent être fournis
 - Exemple: t = std::thread(ma_fonction,param1,param2);

 ⇒ exécution en parallèle de ma_fonction(param1,param2)
 - Sinon le thread est inactif

Classe *«thread»* (2/2)

- Possibilité de transférer le contrôle d'un thread actif
 - \Box Exemple: t1 = t2;
 - Opération de mouvement (dépouillement de «t2»)
 - Si «t2» est actif, alors «t1» devient actif et «t2» inactif
 - Intérêt: permet de séparer les phases de déclaration et de lancement

```
std::thread t;
...
t = std::thread(ma_fonction,param1,param2);
```

- L'exécution d'un thread se termine à la sortie de la fonction associée
- Le thread principal n'attend pas automatiquement la fin des threads qu'il a lancé
 - Attendre chaque thread à l'aide de sa méthode «join»
 - □ Sinon, erreur de conception ⇒ erreurs très probables à l'exécution

Lancement d'un thread

```
void zzz() {
 std::cout << "zzz..." << std::endl;</pre>
 std::this_thread::sleep_for(std::chrono::seconds(1));
int main() {
 std::thread t; // Déclaration d'un thread inactif
t = std::thread(zzz); // Exécution parallèle de la fonction
                       // Objet temporaire = thread actif
                        // Mouvement dans «t»
t.join(); // Attente de la fin du thread
```

Lancement de plusieurs threads

```
void zzz(unsigned n) {
  std::cout << "[" << n << "] zzz..." << std::endl;
  std::this_thread::sleep_for(std::chrono::seconds(1));
}
int main() {
  std::thread t[4];

for (unsigned i = 0; i<4; ++i) t[i] = std::thread(zzz,i);
  for (unsigned i = 0; i<4; ++i) t[i].join();
}</pre>
```

Exécution parallèle d'une lambda

Lambda sans capture

```
t[i] = std::thread(
  [](unsigned n) {
    std::cout << "[" << n << "] zzz..." << std::endl;
    std::this_thread::sleep_for(std::chrono::seconds(1));
}
,i);</pre>
```

Lambda avec capture

```
t[i] = std::thread(
  [=]() {
    std::cout << "[" << i << "] zzz..." << std::endl;
    std::this_thread::sleep_for(std::chrono::seconds(1));
}
);</pre>
```

Accès à une ressource partagée

Exemple précédent, sortie prévue (ordre non garanti)

```
[0] zzz...[1] zzz...[2] zzz...[3] zzz...
```

Mais sortie possible

```
[[01] zzz...] zzz...
[2] zzz...
[3] zzz...
```

- Car problème de partage de ressource
 - La sortie standard est partagée par tous les threads
 - □ Synchronisation nécessaire: chacun son tour ⇒ mutex

Principe du mutex (1/2)

- Mutual exclusion
- Objectif: empêcher l'exécution simultanée d'une portion de code par plusieurs threads
- Mécanisme de jeton
 - Mutex partagé par plusieurs threads
- Acquisition d'un mutex (méthode «lock»)
 - Si le mutex n'est pas verrouillé, le thread obtient l'accès
 - La méthode «lock» se termine
 - □ Si le *mutex* est verrouillé, le *thread* se met en pause
 - La méthode «lock» continue
 - Possibilité d'utiliser la méthode «try_lock» qui n'attend pas

Principe du mutex (2/2)

- Libération d'un mutex (méthode «unlock»)
 - Doit être déclenchée par le thread qui a verrouillé
 - □ Signal aux *threads* en attente \Rightarrow l'un d'eux acquiert alors le *mutex*

```
void zzz(unsigned n) {
  mutex.lock();
  std::cout << "[" << n << "] zzz..." << std::endl;
  mutex.unlock();
  std::this_thread::sleep_for(std::chrono::seconds(1));
}</pre>
```

Eviter l'interblocage de threads (1/2)

- Attention: oubli de libération ⇒ blocage potentiel
 - Thread 1: verrouillage du mutex m
 - □ *Thread* 2: demande d'acquisition de $m \Rightarrow$ attente libération m
 - □ *Thread* 1: fin (sans libérer *m*)
 - Thread principal: attente fin de thread 2...
- Pour éviter les blocages ⇒ toujours utiliser un «verrou»
 - Il s'agit d'un wrapper implémentant l'idiome RAII
 - □ *Wrapper* = objet (verrou) qui encapsule un objet (*mutex*)
 - Il se fait passer pour l'objet ⇒ interface similaire
 - Il contrôle l'appel à ses méthodes
 - □ RAII: Resource Acquisition Is Initialization
 - Le constructeur acquiert le mutex
 - Le destructeur libère le mutex
 - Réduction du risque de blocage des threads

Eviter l'interblocage de threads (2/2)

Plusieurs types de verrous

- lock_guard
 - Interface restreinte: appel explicite à «lock» et «unlock» impossible
 - Copie impossible
 - Remplacé par «scoped_lock» en C++17
- unique_lock
 - Même interface que le mutex
 - Copie impossible, mais mouvement autorisé (⇒ transfert de propriété)

Variable de condition (1/4)

- Mécanisme de synchronisation des threads
- Attendre qu'une condition sur des données partagées se réalise
 - Attente passive du thread (comme l'acquisition d'un mutex)
 - Plusieurs threads peuvent attendre la même condition
 - Méthode «wait»
- Un thread qui change l'état des données surveillées émet un signal vers le ou les threads en attente
 - Méthodes «notify_one» et «notify_all»

Variable de condition (2/4)

- Implémentation: un mutex est nécessaire
- Un mutex est associé à la condition
 - Ce qui permet de synchroniser l'accès aux données partagées
- Signal émis ⇒ un ou plusieurs threads tentent d'acquérir le mutex
 - Le premier qui verrouille le mutex peut vérifier la condition
 - Quel que soit l'état de la condition, le thread devra libérer le mutex
 - Condition fausse ⇒ «wait» libère automatiquement le mutex
 - Condition vraie ⇒ «wait» termine avec le mutex verrouillé
 - Car les autres threads ayant reçu le signal sont en attente du mutex
- Exemple (1/4): variables globales

Variable de condition (3/4)

Exemple (2/4): 1 maître et 3 esclaves

```
int main() {
  std::thread t[4];

t[0] = std::thread(maitre);
  for (unsigned i = 1; i<4; ++i) t[i] = std::thread(esclave,i);
  for (unsigned i = 0; i<4; ++i) t[i].join();
}</pre>
```

Exemple (3/4): les esclaves attendent une condition

```
void esclave(unsigned n) {
  std::unique_lock<std::mutex> verrou(mutex);
  std::cout << "[" << n << "] attend..." << std::endl;
  condition.wait(verrou,[]() { return compteur==5; });
  std::cout << "[" << n << "] termine" << std::endl;
}</pre>
```

Variable de condition (4/4)

Exemple (4/4): le maître modifie les données liées à la condition

```
void maitre(void) {
 for (unsigned i = 0; i < 5; ++i) {
  { std::lock_guard<std::mutex> verrou(mutex);
    std::cout << "[0] compteur = " << compteur << std::endl;</pre>
  std::this_thread::sleep_for(std::chrono::seconds(1));
  { std::lock_guard<std::mutex> verrou(mutex);
    ++compteur; }
  condition.notify_all();
```

Abstraction des threads

- Couche pour masquer les mécanismes multithread
 - Simplifier le code
 - Eviter les interblocages
 - Garantir l'attente de la fin des threads
- Fonction «async»
 - Exécution asynchrone d'un callable
 - Création et démarrage automatique d'un thread
 - Garantie de l'attente de la fin du thread
- Objets «future» et «promise»
 - Mécanisme de synchronisation
 - Attente des résultats d'un thread

Fonction *«async»* (1/2)

- Syntaxe similaire au constructeur d'un thread
 - Arguments: politique d'asynchronisme + callable
 - Politique d'asynchronisme
 - std::launch::async: lancement sur un nouveau thread
 - std::launch::deferred: lancement en mode «lazy»
- Exemple...

```
for (unsigned i = 0; i<4; ++i)
std::async(std::launch::async,zzz,i);</pre>
```

- ...qui ne fait pas ce qu'on pense
 - «async» retourne un objet «future»
 - Son destructeur attend la fin du thread (équivalent de «join»)
 - Dans l'exemple, l'exécution est donc synchrone !!!

Fonction *«async»* (2/2)

- Eviter de laisser un objet «future» dans une rvalue
 - □ Destruction immédiate ⇒ synchronisation
- Stocker l'objet «future» dans une variable locale
 - Variable détruite à la fin du bloc d'instructions
 - Donc bien choisir l'endroit de la déclaration
- Exemple

```
{
std::future<void> f[4];

for (unsigned i = 0; i<4; ++i)
  f[i] = std::async(std::launch::async,zzz,i);

// Attente des threads à la fin du bloc
}</pre>
```

Objet «future» (1/2)

- Représente la valeur retournée par l'exécution d'un thread
 - Encapsule le mécanisme de synchronisation du thread
 - L'attente de la fin du thread est prise en charge
- Méthode «wait»
 - Attend que le résultat soit disponible
 - Autrement dit, que le thread se termine
- Méthode «get»
 - Retourne le résultat une fois qu'il est disponible
 - Attend aussi que le thread se termine
- Si aucune des deux méthodes n'est appelée, le destructeur attend le résultat
 - Afin d'être sûr que la fin du thread sera toujours attendue

```
double calcul(unsigned n) {
 std::this_thread::sleep_for(std::chrono::seconds(1));
 return (n+1) * (n+1);
int main() {
 std::future<double> f[4];
 double somme = 0;
 for (unsigned i = 0; i < 4; ++i)
  f[i] = std::async(std::launch::async,calcul,i);
 for (unsigned i = 0; i < 4; ++i) somme += f[i].get();
 std::cout << "somme = " << somme << std::endl;</pre>
```

Objet *«promise»* (1/2)

- Permet à un thread de fournir un résultat avant la fin de son exécution
- Représente une valeur associée à un objet «future»
 - Lorsque le thread attribue une valeur à un objet «promise»
 - Avec la méthode «set_value»
 - L'objet «future» associé est informé
 - Sa méthode «get» ou «wait» en attente est débloquée
- Exemple (1/2)

Objet *«promise»* (2/2)

- Pas de constructeur de copie
 - Utiliser «std::move» pour invoquer le constructeur de mouvement
- Exemple (2/2)

```
int main() {
 std::promise<double> p1, p2;
 std::future<double> f1 = p1.get_future();
 std::future<double> f2 = p2.get_future();
 std::future<void> f = std::async(std::launch::async,calcul,
                                   std::move(p1),
                                   std::move(p2));
 f1.wait();
 std::cout << "valeur1 = " << f1.get() << std::endl;
 f2.wait();
 std::cout << "valeur2 = " << f2.get() << std::endl;
```